

DAFTAR ISI

DAFTAR ISI	i
DAFTAR TABEL.....	ii
DAFTAR LAMPIRAN	iii
BAB 1. PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Tujuan.....	1
BAB 2. TINJAUAN PUSTAKA.....	2
2.1 Sistem Rekomendasi Berbasis <i>Large Language Model</i>	2
2.2 Tantangan Efisiensi pada Arsitektur LLM	2
2.3 Kompresi Arsitektur LLM dengan <i>Structured Pruning</i>	2
2.4 Adaptasi Domain dengan <i>Quantized Low-Rank Adaptation</i> (QLoRA)	3
2.5 Kebaruan Riset	3
BAB 3. METODE PENELITIAN.....	4
3.1 Pendekatan dan Desain Penelitian	4
3.2 Pengumpulan dan Prapemrosesan Data	4
3.3 Implementasi <i>Structured Pruning</i> dan QLoRA	4
3.4 Rancangan Eksperimen Model	5
3.5 Evaluasi Efisiensi Komputasi	5
3.6 Evaluasi Kualitas Rekomendasi	5
3.7 Analisis Data	6
DAFTAR PUSTAKA	6
Lampiran 1. Penggunaan Dana	8
Lampiran 2. Bukti-bukti pendukung kegiatan	9
Lampiran 3. Business Model Canvas (BMC)	10

DAFTAR TABEL

Tabel 3.1 Rancangan Eksperimen Optimalisasi Model	5
---	---

DAFTAR LAMPIRAN

Lampiran 1. Penggunaan Dana	8
Lampiran 2. Bukti-bukti pendukung kegiatan	9
Lampiran 3. Business Model Canvas (BMC)	10

BAB 1. PENDAHULUAN

1.1 Latar Belakang

Implementasi *Large Language Model* (LLM) pada sistem rekomendasi memiliki potensi yang sangat tinggi dalam memahami preferensi kebutuhan pengguna serta menghasilkan rekomendasi yang lebih personal. Dalam konteks kebutuhan pariwisata khususnya di daerah Toba, kemampuan ini dapat dimanfaatkan untuk membantu penyusunan rekomendasi destinasi atau rencana perjalanan yang lebih sesuai dengan kebutuhan pengguna. Namun, penggunaan LLM dengan ukuran miliaran parameter menghadapi kendala utama berupa tingginya kebutuhan *hardware resource* seperti memori grafis (GPU), waktu respons, dan sumber daya komputasi, terutama ketika diterapkan pada infrastruktur *server* dengan spesifikasi yang terbatas (Yuan *et al.*, 2025).

Untuk mengatasi kendala tersebut, diperlukan strategi optimalisasi model agar sistem rekomendasi tetap efisien tanpa menurunkan kualitas keluaran secara signifikan. *Structured Pruning* digunakan untuk mengurangi bagian model yang kurang penting sehingga ukuran model dan kebutuhan komputasi dapat ditekan (Ma, Fang and Wang, 2023). Sementara itu, *Quantized Low-Rank Adaptation* (QLoRA) digunakan untuk menyesuaikan model dengan kebutuhan memori yang lebih rendah selama proses *fine-tuning* (Dettmers *et al.*, 2023). Kombinasi kedua metode ini diharapkan dapat menghasilkan model yang lebih ringan, cepat, dan tetap mampu memberikan rekomendasi yang relevan.

Meskipun *Structured Pruning* dan QLoRA telah banyak diteliti secara terpisah, kajian mengenai integrasi keduanya pada sistem rekomendasi berbasis LLM, khususnya untuk domain pariwisata lokal, masih terbatas. Oleh karena itu, penelitian ini dilakukan untuk mengevaluasi pengaruh integrasi *Structured Pruning* dan QLoRA terhadap efisiensi komputasi serta kualitas keluaran sistem rekomendasi pariwisata Danau Toba. Penelitian ini juga bertujuan untuk menemukan konfigurasi terbaik yang mampu menyeimbangkan penghematan sumber daya komputasi dan akurasi rekomendasi.

1.2 Tujuan

Sejalan dengan rumusan masalah di atas, tujuan dari kegiatan ini adalah:

1. Mengukur dan menganalisis efektivitas penggabungan metode *Structured Pruning* dan *QLoRA* dalam mereduksi beban komputasi memori pada model *Qwen*.
2. Mengevaluasi keseimbangan antara efisiensi komputasi (kecepatan inferensi) dan kualitas respon rekomendasi untuk menentukan konfigurasi model yang paling optimal pada sistem rekomendasi pariwisata Danau Toba.

BAB 2. TINJAUAN PUSTAKA

2.1 Sistem Rekomendasi Berbasis *Large Language Model*

Sistem rekomendasi digunakan untuk membantu pengguna menemukan pilihan yang sesuai dengan kebutuhannya. Metode tradisional seperti *Collaborative Filtering* memprediksi preferensi pengguna berdasarkan pola interaksi antara pengguna dan item. Namun, metode ini masih memiliki keterbatasan, terutama pada kondisi data yang sedikit dan ketika sistem perlu memahami kebutuhan pengguna dalam bentuk bahasa alami. *Large Language Model (LLM)* dapat membantu mengatasi keterbatasan tersebut karena mampu memproses instruksi teks dan memahami konteks preferensi pengguna dengan lebih baik (Tsai *et al.*, 2024).

Dalam penelitian ini, LLM digunakan sebagai dasar sistem rekomendasi pariwisata Danau Toba. Model diarahkan untuk memproses informasi destinasi dan kebutuhan pengguna sehingga dapat menghasilkan rekomendasi yang lebih relevan. Dengan kemampuan pemrosesan bahasa alami, LLM berpotensi digunakan sebagai asisten digital untuk membantu penyusunan rekomendasi destinasi atau rencana perjalanan wisata (Bonin, Heuillet and Durand, 2025).

2.2 Tantangan Efisiensi pada Arsitektur LLM

Model bahasa berskala besar seperti Qwen memiliki kemampuan generatif yang baik karena didukung oleh arsitektur transformer dan jumlah parameter yang besar. Namun, jumlah parameter yang besar juga menyebabkan kebutuhan memori GPU dan waktu komputasi menjadi tinggi, baik pada proses fine-tuning maupun inferensi (Yuan *et al.*, 2025).

Kondisi tersebut menjadi tantangan ketika model akan diterapkan pada server dengan spesifikasi terbatas. Keterbatasan memori dapat menyebabkan memory bottleneck, yaitu kondisi ketika penggunaan memori menjadi penghambat utama dalam proses komputasi dan berdampak pada meningkatnya waktu respons sistem (Behera *et al.*, 2025). Oleh karena itu, diperlukan proses optimalisasi agar model tetap dapat berjalan secara efisien tanpa menurunkan kualitas keluaran secara signifikan.

2.3 Kompresi Arsitektur LLM dengan *Structured Pruning*

Kompresi model merupakan salah satu pendekatan yang dapat digunakan untuk menurunkan beban komputasi pada LLM. Salah satu metode kompresi yang digunakan adalah *Structured Pruning*. Metode ini bekerja dengan mengurangi bagian struktur model tertentu yang dianggap kurang penting, seperti attention head atau bagian parameter lain yang redundan. Berbeda dengan pruning tidak terstruktur yang hanya mengubah bobot individual, *Structured Pruning* lebih berpengaruh terhadap efisiensi perangkat keras karena mengurangi struktur model secara langsung (Ma, Fang and Wang, 2023).

Dalam sistem rekomendasi, proses *pruning* perlu dilakukan secara hati-hati agar tidak menghilangkan kemampuan utama model dalam memahami instruksi dan menghasilkan rekomendasi. Oleh karena itu, *task-aware pruning* menjadi pendekatan yang penting karena pemangkasan dilakukan dengan mempertimbangkan tugas yang dikerjakan oleh model. Pendekatan ini membantu memilih bagian model yang kurang relevan terhadap tugas utama sehingga beban komputasi dapat dikurangi dengan tetap menjaga kualitas rekomendasi (Tian *et al.*, 2025).

2.4 Adaptasi Domain dengan *Quantized Low-Rank Adaptation* (QLoRA)

Setelah model dikompresi, proses *fine-tuning* tetap diperlukan agar model dapat menyesuaikan diri dengan domain yang digunakan. Pada penelitian ini, domain yang digunakan adalah rekomendasi pariwisata Danau Toba. Namun, *fine-tuning* seluruh parameter LLM membutuhkan memori GPU yang besar. Oleh karena itu, diperlukan metode *fine-tuning* yang lebih efisien.

Quantized Low-Rank Adaptation (QLoRA) merupakan metode *fine-tuning* yang dirancang untuk mengurangi kebutuhan memori. Metode ini membekukan sebagian besar parameter model dalam format presisi rendah dan hanya melatih adapter berukuran kecil. Dengan cara ini, proses adaptasi model dapat dilakukan dengan kebutuhan memori yang lebih rendah dibandingkan *fine-tuning* penuh (Dettmers *et al.*, 2023). Dalam penelitian ini, QLoRA digunakan untuk membantu memulihkan performa model setelah proses *Structured Pruning* sehingga sistem rekomendasi tetap efisien dan relevan.

2.5 Kebaruan Riset

Penelitian sebelumnya telah membahas *Structured Pruning* dan QLoRA sebagai pendekatan untuk meningkatkan efisiensi LLM. *Structured Pruning* digunakan untuk mengurangi ukuran dan beban komputasi model (Ma, Fang and Wang, 2023), sedangkan QLoRA digunakan untuk melakukan *fine-tuning* dengan kebutuhan memori yang lebih rendah (Dettmers *et al.*, 2023). Namun, kedua metode tersebut umumnya masih banyak dikaji secara terpisah.

Kebaruan penelitian ini terletak pada integrasi *Structured Pruning* dan QLoRA secara berurutan pada model Qwen untuk sistem rekomendasi pariwisata Danau Toba. Penelitian ini mengevaluasi pengaruh kompresi model terhadap dua aspek utama, yaitu efisiensi komputasi dan kualitas rekomendasi. Efisiensi komputasi dianalisis melalui metrik seperti *Peak VRAM*, *latency*, *Time-to-First-Token* (TTFT), dan *throughput*, sedangkan kualitas rekomendasi dianalisis menggunakan metrik *NDCG*, *Hit Rate*, *Recall*, dan *Precision*. Dengan demikian, penelitian ini diharapkan dapat memberikan gambaran mengenai konfigurasi model yang paling seimbang antara kecepatan, penggunaan memori, dan kualitas rekomendasi.

BAB 3. METODE PENELITIAN

3.1 Pendekatan dan Desain Penelitian

Penelitian ini menggunakan pendekatan eksperimen kuantitatif. Eksperimen dilakukan dengan membandingkan performa model dasar Qwen dengan beberapa model hasil optimasi menggunakan *Structured Pruning* dan *Quantized Low-Rank Adaptation* (QLoRA). Perbandingan dilakukan untuk mengetahui pengaruh kompresi model terhadap efisiensi komputasi dan kualitas rekomendasi pariwisata Danau Toba.

Model baseline digunakan sebagai acuan awal. Selanjutnya, model diuji pada beberapa rasio *pruning*, yaitu 10%, 20%, dan 30%. Setiap model hasil *pruning* diuji dalam dua kondisi, yaitu tanpa fine-tuning dan dengan *fine-tuning* menggunakan QLoRA. Hasil dari seluruh varian model kemudian dibandingkan untuk menentukan konfigurasi yang paling seimbang antara penggunaan memori, kecepatan inferensi, dan kualitas rekomendasi.

3.2 Pengumpulan dan Prapemrosesan Data

Data yang digunakan dalam penelitian ini berupa dataset destinasi dan ulasan pariwisata Danau Toba. Data tersebut digunakan sebagai sumber informasi untuk membangun sistem rekomendasi dan menguji kemampuan model dalam menghasilkan rekomendasi destinasi wisata.

Tahap prapemrosesan dilakukan dengan membersihkan data, menghapus data yang tidak lengkap, dan menyiapkan teks agar dapat diproses oleh sistem. Data teks kemudian dipotong menjadi beberapa bagian menggunakan teknik sliding window. Setiap bagian teks diubah menjadi representasi vektor menggunakan model embedding, lalu disimpan ke dalam ChromaDB. Hasil penyimpanan vektor ini digunakan untuk mendukung proses pencarian informasi yang relevan selama pengujian rekomendasi.

3.3 Implementasi *Structured Pruning* dan QLoRA

Structured Pruning digunakan untuk mengurangi bagian struktur model yang dianggap kurang penting. Pada penelitian ini, pruning dilakukan pada beberapa rasio pemangkasan, yaitu 10%, 20%, dan 30%. Tujuan dari tahap ini adalah menurunkan ukuran model dan beban komputasi sehingga proses inferensi dapat berjalan lebih efisien.

Setelah proses pruning, beberapa model hasil pemangkasan dilanjutkan ke tahap fine-tuning menggunakan QLoRA. *Fine-tuning* ini dilakukan untuk membantu model menyesuaikan kembali performanya setelah proses pemangkasan. QLoRA digunakan karena metode ini dapat melakukan adaptasi model dengan kebutuhan memori yang lebih rendah dibandingkan *fine-tuning* penuh.

3.4 Rancangan Eksperimen Model

Eksperimen dilakukan terhadap tujuh varian model, yaitu satu model baseline, tiga model hasil pruning tanpa fine-tuning, dan tiga model hasil pruning dengan fine-tuning QLoRA. Rancangan eksperimen ditunjukkan pada Tabel 3.1.

Tabel 3.1 Rancangan Eksperimen Optimalisasi Model

Skenario	Rasio Pruning	Rank QLoRA (r)	Keterangan
1 (<i>Baseline</i>)	0%	0	Sebagai tolok ukur awal performa <i>Qwen</i>
2	10%	8	Pemangkasan ringan dengan adaptasi rendah
3	20%	16	Pemangkasan menengah dengan adaptasi sedang
4	30%	32	Pemangkasan ekstrem dengan adaptasi tinggi

Setiap varian model diuji menggunakan kumpulan kueri yang sama. Penggunaan kueri yang sama bertujuan agar hasil pengukuran setiap model dapat dibandingkan secara adil. Pengujian dilakukan untuk memperoleh data efisiensi komputasi dan data kualitas rekomendasi.

3.5 Evaluasi Efisiensi Komputasi

Evaluasi efisiensi komputasi dilakukan untuk mengetahui pengaruh pruning dan QLoRA terhadap kebutuhan sumber daya model. Metrik yang digunakan meliputi *Peak VRAM*, *latency*, *Time To First Token (TTFT)*, dan *throughput*.

Peak VRAM digunakan untuk mengukur penggunaan memori GPU tertinggi selama proses inferensi. *Latency* digunakan untuk mengukur total waktu yang dibutuhkan model dalam menghasilkan respons. *TTFT* digunakan untuk mengukur waktu yang dibutuhkan model sampai token pertama muncul. *Throughput* digunakan untuk mengukur jumlah token yang dapat dihasilkan model per detik.

3.6 Evaluasi Kualitas Rekomendasi

Evaluasi kualitas rekomendasi dilakukan untuk mengetahui apakah proses kompresi model memengaruhi kualitas hasil rekomendasi. Metrik yang digunakan meliputi *Normalize Discounted Cumulative Gain (NDCG)* *NDCG@10*, *Recall@10*, *Hit Rate@10*, *Precision@10*, dan *Parse Success Rate*.

NDCG@10 digunakan untuk menilai kualitas urutan rekomendasi yang dihasilkan model. *Recall@10* digunakan untuk mengukur kemampuan model menemukan item relevan dalam 10 rekomendasi teratas. *Hit Rate@10* digunakan untuk melihat apakah minimal satu item relevan muncul dalam daftar 10 rekomendasi teratas. *Precision@10* digunakan untuk mengukur ketepatan item relevan dalam hasil

rekomendasi. Parse Success Rate digunakan untuk mengukur keberhasilan model menghasilkan keluaran dengan format yang dapat diproses.

Nilai NDCG@K dihitung menggunakan persamaan berikut.

$$NDCG@K(u) = \frac{DCG@K}{IDCG@K}$$

Pada persamaan tersebut, DCG@K merupakan skor relevansi aktual dari urutan rekomendasi, sedangkan IDCG@K merupakan skor relevansi ideal maksimum. Semakin tinggi nilai NDCG, semakin baik kualitas urutan rekomendasi yang dihasilkan.

3.7 Analisis Data

Data hasil eksperimen dianalisis secara deskriptif dan komparatif. Analisis deskriptif digunakan untuk melihat nilai rata-rata dari setiap metrik pada masing-masing varian model. Analisis komparatif digunakan untuk membandingkan model baseline dengan model hasil pruning dan fine-tuning.

Efektivitas pengurangan ukuran model dihitung menggunakan rasio kompresi dengan persamaan berikut.

$$CR = \left(1 - \frac{P_{akhir}}{P_{awal}}\right) \times 100\%$$

Pada persamaan tersebut, CR adalah rasio kompresi, P_{akhir} adalah jumlah parameter model setelah pruning, dan P_{awal} adalah jumlah parameter model sebelum pruning. Hasil analisis digunakan untuk menentukan konfigurasi model yang paling optimal berdasarkan keseimbangan antara efisiensi komputasi dan kualitas rekomendasi.

DAFTAR PUSTAKA

- Behera, A.P. *et al.* (2025) "Towards Efficient Multi-LLM Inference: Characterization and Analysis of LLM Routing and Hierarchical Techniques," 14(8), pp. 1–16.
- Bonin, B., Heuillet, M. and Durand, A. (2025) "LLM-as-a-Judge: Toward World Models for Slate Recommendation Systems," (i).
- Dettmers, T. *et al.* (2023) "QLORA: Efficient Finetuning of Quantized LLMs," *Advances in Neural Information Processing Systems*, 36. Available at: <https://doi.org/https://doi.org/10.48550/arXiv.2305.14314>.
- Ma, X., Fang, G. and Wang, X. (2023) "LLM-Pruner: On the Structural Pruning of Large Language Models," *Advances in Neural Information Processing Systems*, 36. Available at: <https://doi.org/https://doi.org/10.48550/arXiv.2305.11627>.
- Tian, Y. *et al.* (2025) "Frustratingly Easy Task-aware Pruning for Large Language Models," pp. 1–8. Available at: <https://doi.org/https://doi.org/10.48550/arXiv.2510.22489>.

Tsai, A.Y. *et al.* (2024) “Leveraging LLM Reasoning Enhances Personalized Recommender Systems.”

Yuan, Z. *et al.* (2025) “EfficientLLM: Efficiency in Large Language Models.”
Available at: <https://doi.org/https://doi.org/10.48550/arXiv.2505.13840>.


LAMPIRAN

Lampiran 1. Penggunaan Dana


Judul	OPTIMALISASI LARGE LANGUAGE MODEL DENGAN METODE STRUCTURED PRUNING DAN KUANTISASI UNTUK MENINGKATKAN EFISIENSI SISTEM REKOMENDASI PARIWISATA DANAU TOBA			
Skema	Tahun	Pendanaan	Penggunaan	Sisa
PKM-RE	2026	Rp 7.200.000	Rp.	Rp.

No	Tanggal	Keterangan	Harga Satuan	Jumlah	Total	Berkas	Validasi
1	06-04-2026		Rp.		Rp.		
2	07-04-2026		Rp.		Rp.		
3	08-04-2026		Rp.		Rp.		
4	09-04-2026		Rp.		Rp.		
5	10-04-2026		Rp.		Rp.		


Lampiran 2. Bukti-bukti pendukung kegiatan




Qwen-14B Optimization Analysis: Structured Pruning + QLoRA (V3)



Evaluation of Qwen-14B Optimization Strategies (Lake Toba Tourism Task)



Lampiran 3. Business Model Canvas (BMC)



Link to Miro:

https://miro.com/app/board/uXjVHTVRGhk=?share_link_id=30052723993

Logbook

Judul	Pengembangan Aplikasi Pembelajaran Pemrograman berbasis Kecerdasan Buatan dengan Fitur Pembuatan Soal Otomatis dan Pendekatan Pembelajaran Adaptif sesuai Kemampuan Mahasiswa				
Skema	Tahun	Dana Disetujui	Capaian (%)	Total Waktu (Menit)	Rekomendasi sks
PKM-RE	2026	Rp 7.200.000			-

No	Tanggal Pelaksanaan	Kegiatan	Capaian (%)	Waktu Pelaksanaan (Menit)	Berkas	Validasi Dosen
1	06-04-2026					
2	07-04-2026					
3	08-04-2026					
4	09-04-2026					
5	10-04-2026					
6	11-04-2026					