

RINGKASAN

Large Language Model (LLM) memiliki potensi besar untuk digunakan dalam sistem rekomendasi karena mampu memahami preferensi pengguna dan menghasilkan rekomendasi berbasis bahasa alami. Namun, penggunaan LLM berukuran besar masih memiliki kendala utama berupa kebutuhan memori GPU yang tinggi dan waktu respons yang lama. Penelitian ini bertujuan untuk mengevaluasi efektivitas integrasi Structured Pruning dan Quantized Low-Rank Adaptation (QLoRA) dalam meningkatkan efisiensi model Qwen3-14B pada sistem rekomendasi pariwisata Danau Toba.

Penelitian dilakukan dengan pendekatan eksperimen kuantitatif menggunakan tujuh varian model, yaitu model baseline, model hasil pruning 10%, 20%, dan 30% tanpa fine-tuning, serta model hasil pruning 10%, 20%, dan 30% dengan fine-tuning QLoRA. Dataset yang digunakan berupa data destinasi dan ulasan pariwisata Danau Toba. Evaluasi dilakukan menggunakan dua aspek utama, yaitu efisiensi komputasi dan kualitas rekomendasi. Efisiensi komputasi diukur melalui Peak VRAM, latency, Time To First Token (TTFT), dan throughput, sedangkan kualitas rekomendasi diukur menggunakan NDCG@10, Recall@10, Hit Rate@10, Precision@10, dan Parse Success Rate.

Hasil penelitian menunjukkan bahwa Structured Pruning mampu menurunkan kebutuhan komputasi model secara signifikan. Peak VRAM menurun dari 27,70 GB pada model baseline menjadi 21,67 GB pada konfigurasi pruning 30%. Total latency juga menurun dari 2,31 detik menjadi sekitar 0,59–0,70 detik pada model hasil pruning. Dari sisi kualitas rekomendasi, model baseline memperoleh NDCG@10 tertinggi sebesar 0,8409. Namun, varian Pruned_20P_FT masih mampu mempertahankan kualitas yang mendekati baseline dengan NDCG@10 sebesar 0,8321, sekaligus menurunkan Peak VRAM sebesar 14,86% dan mempercepat latency sebesar 70,29%.

Berdasarkan hasil tersebut, konfigurasi Pruned_20P_FT menjadi pilihan terbaik karena memberikan keseimbangan paling baik antara efisiensi komputasi dan kualitas rekomendasi. Penelitian ini menunjukkan bahwa integrasi Structured Pruning dan QLoRA berpotensi digunakan untuk mengembangkan sistem rekomendasi berbasis LLM yang lebih ringan, cepat, dan tetap relevan, khususnya pada domain pariwisata lokal seperti Danau Toba.

Kata kunci: Large Language Model, Structured Pruning, QLoRA, sistem rekomendasi, Danau Toba.

DAFTAR ISI

RINGKASAN	i
DAFTAR ISI	i
DAFTAR TABEL.....	ii
DAFTAR GAMBAR	iii
DAFTAR LAMPIRAN	iv
BAB 1. PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Tujuan.....	1
BAB 2. TINJAUAN PUSTAKA.....	2
2.1 Sistem Rekomendasi Berbasis <i>Large Language Model</i>	2
2.2 Tantangan Efisiensi pada Arsitektur LLM	2
2.3 Kompresi Arsitektur LLM dengan <i>Structured Pruning</i>	2
2.4 Adaptasi Domain dengan <i>Quantized Low-Rank Adaptation (QLoRA)</i>	3
2.5 Kebaruan Riset	3
BAB 3. METODE PENELITIAN.....	4
3.1 Pendekatan dan Desain Penelitian	4
3.2 Pengumpulan dan Prapemrosesan Data	4
3.3 Implementasi Structured Pruning dan QLoRA	4
3.4 Rancangan Eksperimen Model	5
3.5 Evaluasi Efisiensi Komputasi	5
3.6 Evaluasi Kualitas Rekomendasi	5
3.7 Analisis Data	6
BAB 4. HASIL YANG DICAPAI DAN POTENSI KHUSUS	6
4.1 Hasil yang Dicapai	6
4.1.1 Hasil Evaluasi Efisiensi Komputasi	7
4.1.2 Hasil Evaluasi Kualitas Rekomendasi	7
4.3 Analisis <i>Trade-off</i> Model	7
4.4 Potensi Khusus Hasil Penelitian	9
BAB 5. PENUTUP	9
5.1 Kesimpulan	9
5.2 Saran.....	10
DAFTAR PUSTAKA	10
Lampiran 1. Penggunaan Dana	10
Lampiran 2. Bukti-bukti pendukung kegiatan	12
Lampiran 3. Bussiness Model Canvas (BMC).....	16

DAFTAR TABEL

Tabel 3.1 Rancangan Eksperimen Optimalisasi Model	5
Tabel 4.1 Ringkasan Hasil Evaluasi Model	6

DAFTAR GAMBAR

Gambar 4.1 Kurva Trade-off Kualitas Rekomendasi terhadap Efisiensi Komputasi:
(a) NDCG@10 terhadap Latency dan (b) NDCG@10 terhadap Peak VRAM..... 8

DAFTAR LAMPIRAN

Lampiran 1. Penggunaan Dana	8
Lampiran 2. Bukti-bukti pendukung kegiatan	9
Lampiran 3. Business Model Canvas (BMC)	10

BAB 1. PENDAHULUAN

1.1 Latar Belakang

Implementasi *Large Language Model* (LLM) pada sistem rekomendasi memiliki potensi yang sangat tinggi dalam memahami preferensi kebutuhan pengguna serta menghasilkan rekomendasi yang lebih personal. Dalam konteks kebutuhan pariwisata khususnya di daerah Toba, kemampuan ini dapat dimanfaatkan untuk membantu penyusunan rekomendasi destinasi atau rencana perjalanan yang lebih sesuai dengan kebutuhan pengguna. Namun, penggunaan LLM dengan ukuran miliaran parameter menghadapi kendala utama berupa tingginya kebutuhan *hardware resource* seperti memori grafis (GPU), waktu respons, dan sumber daya komputasi, terutama ketika diterapkan pada infrastruktur *server* dengan spesifikasi yang terbatas (Yuan *et al.*, 2025).

Untuk mengatasi kendala tersebut, diperlukan strategi optimalisasi model agar sistem rekomendasi tetap efisien tanpa menurunkan kualitas keluaran secara signifikan. *Structured Pruning* digunakan untuk mengurangi bagian model yang kurang penting sehingga ukuran model dan kebutuhan komputasi dapat ditekan (Ma, Fang and Wang, 2023). Sementara itu, *Quantized Low-Rank Adaptation* (QLoRA) digunakan untuk menyesuaikan model dengan kebutuhan memori yang lebih rendah selama proses *fine-tuning* (Dettmers *et al.*, 2023). Kombinasi kedua metode ini diharapkan dapat menghasilkan model yang lebih ringan, cepat, dan tetap mampu memberikan rekomendasi yang relevan.

Meskipun *Structured Pruning* dan QLoRA telah banyak diteliti secara terpisah, kajian mengenai integrasi keduanya pada sistem rekomendasi berbasis LLM, khususnya untuk domain pariwisata lokal, masih terbatas. Oleh karena itu, penelitian ini dilakukan untuk mengevaluasi pengaruh integrasi *Structured Pruning* dan QLoRA terhadap efisiensi komputasi serta kualitas keluaran sistem rekomendasi pariwisata Danau Toba. Penelitian ini juga bertujuan untuk menemukan konfigurasi terbaik yang mampu menyeimbangkan penghematan sumber daya komputasi dan akurasi rekomendasi.

1.2 Tujuan

Sejalan dengan rumusan masalah di atas, tujuan dari kegiatan ini adalah:

1. Mengukur dan menganalisis efektivitas penggabungan metode *Structured Pruning* dan *QLoRA* dalam mereduksi beban komputasi memori pada model *Qwen*.
2. Mengevaluasi keseimbangan antara efisiensi komputasi (kecepatan inferensi) dan kualitas respon rekomendasi untuk menentukan konfigurasi model yang paling optimal pada sistem rekomendasi pariwisata Danau Toba.

BAB 2. TINJAUAN PUSTAKA

2.1 Sistem Rekomendasi Berbasis *Large Language Model*

Sistem rekomendasi digunakan untuk membantu pengguna menemukan pilihan yang sesuai dengan kebutuhannya. Metode tradisional seperti *Collaborative Filtering* memprediksi preferensi pengguna berdasarkan pola interaksi antara pengguna dan item. Namun, metode ini masih memiliki keterbatasan, terutama pada kondisi data yang sedikit dan ketika sistem perlu memahami kebutuhan pengguna dalam bentuk bahasa alami. *Large Language Model (LLM)* dapat membantu mengatasi keterbatasan tersebut karena mampu memproses instruksi teks dan memahami konteks preferensi pengguna dengan lebih baik (Tsai *et al.*, 2024).

Dalam penelitian ini, LLM digunakan sebagai dasar sistem rekomendasi pariwisata Danau Toba. Model diarahkan untuk memproses informasi destinasi dan kebutuhan pengguna sehingga dapat menghasilkan rekomendasi yang lebih relevan. Dengan kemampuan pemrosesan bahasa alami, LLM berpotensi digunakan sebagai asisten digital untuk membantu penyusunan rekomendasi destinasi atau rencana perjalanan wisata (Bonin, Heuillet and Durand, 2025).

2.2 Tantangan Efisiensi pada Arsitektur LLM

Model bahasa berskala besar seperti Qwen memiliki kemampuan generatif yang baik karena didukung oleh arsitektur transformer dan jumlah parameter yang besar. Namun, jumlah parameter yang besar juga menyebabkan kebutuhan memori GPU dan waktu komputasi menjadi tinggi, baik pada proses fine-tuning maupun inferensi (Yuan *et al.*, 2025).

Kondisi tersebut menjadi tantangan ketika model akan diterapkan pada server dengan spesifikasi terbatas. Keterbatasan memori dapat menyebabkan memory bottleneck, yaitu kondisi ketika penggunaan memori menjadi penghambat utama dalam proses komputasi dan berdampak pada meningkatnya waktu respons sistem (Behera *et al.*, 2025). Oleh karena itu, diperlukan proses optimalisasi agar model tetap dapat berjalan secara efisien tanpa menurunkan kualitas keluaran secara signifikan.

2.3 Kompresi Arsitektur LLM dengan *Structured Pruning*

Kompresi model merupakan salah satu pendekatan yang dapat digunakan untuk menurunkan beban komputasi pada LLM. Salah satu metode kompresi yang digunakan adalah *Structured Pruning*. Metode ini bekerja dengan mengurangi bagian struktur model tertentu yang dianggap kurang penting, seperti attention head atau bagian parameter lain yang redundan. Berbeda dengan pruning tidak terstruktur yang hanya mengubah bobot individual, *Structured Pruning* lebih berpengaruh terhadap efisiensi perangkat keras karena mengurangi struktur model secara langsung (Ma, Fang and Wang, 2023).

Dalam sistem rekomendasi, proses *pruning* perlu dilakukan secara hati-hati agar tidak menghilangkan kemampuan utama model dalam memahami instruksi dan menghasilkan rekomendasi. Oleh karena itu, *task-aware pruning* menjadi pendekatan yang penting karena pemangkasan dilakukan dengan mempertimbangkan tugas yang dikerjakan oleh model. Pendekatan ini membantu memilih bagian model yang kurang relevan terhadap tugas utama sehingga beban komputasi dapat dikurangi dengan tetap menjaga kualitas rekomendasi (Tian *et al.*, 2025).

2.4 Adaptasi Domain dengan *Quantized Low-Rank Adaptation* (QLoRA)

Setelah model dikompresi, proses *fine-tuning* tetap diperlukan agar model dapat menyesuaikan diri dengan domain yang digunakan. Pada penelitian ini, domain yang digunakan adalah rekomendasi pariwisata Danau Toba. Namun, *fine-tuning* seluruh parameter LLM membutuhkan memori GPU yang besar. Oleh karena itu, diperlukan metode *fine-tuning* yang lebih efisien.

Quantized Low-Rank Adaptation (QLoRA) merupakan metode *fine-tuning* yang dirancang untuk mengurangi kebutuhan memori. Metode ini membekukan sebagian besar parameter model dalam format presisi rendah dan hanya melatih adapter berukuran kecil. Dengan cara ini, proses adaptasi model dapat dilakukan dengan kebutuhan memori yang lebih rendah dibandingkan *fine-tuning* penuh (Dettmers *et al.*, 2023). Dalam penelitian ini, QLoRA digunakan untuk membantu memulihkan performa model setelah proses *Structured Pruning* sehingga sistem rekomendasi tetap efisien dan relevan.

2.5 Kebaruan Riset

Penelitian sebelumnya telah membahas *Structured Pruning* dan QLoRA sebagai pendekatan untuk meningkatkan efisiensi LLM. *Structured Pruning* digunakan untuk mengurangi ukuran dan beban komputasi model (Ma, Fang and Wang, 2023), sedangkan QLoRA digunakan untuk melakukan *fine-tuning* dengan kebutuhan memori yang lebih rendah (Dettmers *et al.*, 2023). Namun, kedua metode tersebut umumnya masih banyak dikaji secara terpisah.

Kebaruan penelitian ini terletak pada integrasi *Structured Pruning* dan QLoRA secara berurutan pada model Qwen untuk sistem rekomendasi pariwisata Danau Toba. Penelitian ini mengevaluasi pengaruh kompresi model terhadap dua aspek utama, yaitu efisiensi komputasi dan kualitas rekomendasi. Efisiensi komputasi dianalisis melalui metrik seperti *Peak VRAM*, *latency*, *Time-to-First-Token* (TTFT), dan *throughput*, sedangkan kualitas rekomendasi dianalisis menggunakan metrik *NDCG*, *Hit Rate*, *Recall*, dan *Precision*. Dengan demikian, penelitian ini diharapkan dapat memberikan gambaran mengenai konfigurasi model yang paling seimbang antara kecepatan, penggunaan memori, dan kualitas rekomendasi.

BAB 3. METODE PENELITIAN

3.1 Pendekatan dan Desain Penelitian

Penelitian ini menggunakan pendekatan eksperimen kuantitatif. Eksperimen dilakukan dengan membandingkan performa model dasar Qwen dengan beberapa model hasil optimasi menggunakan *Structured Pruning* dan *Quantized Low-Rank Adaptation* (QLoRA). Perbandingan dilakukan untuk mengetahui pengaruh kompresi model terhadap efisiensi komputasi dan kualitas rekomendasi pariwisata Danau Toba.

Model baseline digunakan sebagai acuan awal. Selanjutnya, model diuji pada beberapa rasio *pruning*, yaitu 10%, 20%, dan 30%. Setiap model hasil *pruning* diuji dalam dua kondisi, yaitu tanpa fine-tuning dan dengan *fine-tuning* menggunakan QLoRA. Hasil dari seluruh varian model kemudian dibandingkan untuk menentukan konfigurasi yang paling seimbang antara penggunaan memori, kecepatan inferensi, dan kualitas rekomendasi.

3.2 Pengumpulan dan Prapemrosesan Data

Data yang digunakan dalam penelitian ini berupa dataset destinasi dan ulasan pariwisata Danau Toba. Data tersebut digunakan sebagai sumber informasi untuk membangun sistem rekomendasi dan menguji kemampuan model dalam menghasilkan rekomendasi destinasi wisata.

Tahap prapemrosesan dilakukan dengan membersihkan data, menghapus data yang tidak lengkap, dan menyiapkan teks agar dapat diproses oleh sistem. Data teks kemudian dipotong menjadi beberapa bagian menggunakan teknik sliding window. Setiap bagian teks diubah menjadi representasi vektor menggunakan model embedding, lalu disimpan ke dalam ChromaDB. Hasil penyimpanan vektor ini digunakan untuk mendukung proses pencarian informasi yang relevan selama pengujian rekomendasi.

3.3 Implementasi *Structured Pruning* dan QLoRA

Structured Pruning digunakan untuk mengurangi bagian struktur model yang dianggap kurang penting. Pada penelitian ini, pruning dilakukan pada beberapa rasio pemangkasan, yaitu 10%, 20%, dan 30%. Tujuan dari tahap ini adalah menurunkan ukuran model dan beban komputasi sehingga proses inferensi dapat berjalan lebih efisien.

Setelah proses pruning, beberapa model hasil pemangkasan dilanjutkan ke tahap fine-tuning menggunakan QLoRA. *Fine-tuning* ini dilakukan untuk membantu model menyesuaikan kembali performanya setelah proses pemangkasan. QLoRA digunakan karena metode ini dapat melakukan adaptasi model dengan kebutuhan memori yang lebih rendah dibandingkan *fine-tuning* penuh.

3.4 Rancangan Eksperimen Model

Eksperimen dilakukan terhadap tujuh varian model, yaitu satu model baseline, tiga model hasil pruning tanpa fine-tuning, dan tiga model hasil pruning dengan fine-tuning QLoRA. Rancangan eksperimen ditunjukkan pada Tabel 3.1.

Tabel 3.1 Rancangan Eksperimen Optimalisasi Model

Skenario	Rasio Pruning	Rank QLoRA (r)	Keterangan
1 (<i>Baseline</i>)	0%	0	Sebagai tolok ukur awal performa <i>Qwen</i>
2	10%	8	Pemangkasan ringan dengan adaptasi rendah
3	20%	16	Pemangkasan menengah dengan adaptasi sedang
4	30%	32	Pemangkasan ekstrem dengan adaptasi tinggi

Setiap varian model diuji menggunakan kumpulan kueri yang sama. Penggunaan kueri yang sama bertujuan agar hasil pengukuran setiap model dapat dibandingkan secara adil. Pengujian dilakukan untuk memperoleh data efisiensi komputasi dan data kualitas rekomendasi.

3.5 Evaluasi Efisiensi Komputasi

Evaluasi efisiensi komputasi dilakukan untuk mengetahui pengaruh pruning dan QLoRA terhadap kebutuhan sumber daya model. Metrik yang digunakan meliputi *Peak VRAM*, *latency*, *Time To First Token (TTFT)*, dan *throughput*.

Peak VRAM digunakan untuk mengukur penggunaan memori GPU tertinggi selama proses inferensi. *Latency* digunakan untuk mengukur total waktu yang dibutuhkan model dalam menghasilkan respons. *TTFT* digunakan untuk mengukur waktu yang dibutuhkan model sampai token pertama muncul. *Throughput* digunakan untuk mengukur jumlah token yang dapat dihasilkan model per detik.

3.6 Evaluasi Kualitas Rekomendasi

Evaluasi kualitas rekomendasi dilakukan untuk mengetahui apakah proses kompresi model memengaruhi kualitas hasil rekomendasi. Metrik yang digunakan meliputi *Normalize Discounted Cumulative Gain (NDCG)* *NDCG@10*, *Recall@10*, *Hit Rate@10*, *Precision@10*, dan *Parse Success Rate*.

NDCG@10 digunakan untuk menilai kualitas urutan rekomendasi yang dihasilkan model. *Recall@10* digunakan untuk mengukur kemampuan model menemukan item relevan dalam 10 rekomendasi teratas. *Hit Rate@10* digunakan untuk melihat apakah minimal satu item relevan muncul dalam daftar 10 rekomendasi teratas. *Precision@10* digunakan untuk mengukur ketepatan item relevan dalam hasil

rekomendasi. Parse Success Rate digunakan untuk mengukur keberhasilan model menghasilkan keluaran dengan format yang dapat diproses.

Nilai NDCG@K dihitung menggunakan persamaan berikut.

$$NDCG@K(u) = \frac{DCG@K}{IDCG@K}$$

Pada persamaan tersebut, DCG@K merupakan skor relevansi aktual dari urutan rekomendasi, sedangkan IDCG@K merupakan skor relevansi ideal maksimum. Semakin tinggi nilai NDCG, semakin baik kualitas urutan rekomendasi yang dihasilkan.

3.7 Analisis Data

Data hasil eksperimen dianalisis secara deskriptif dan komparatif. Analisis deskriptif digunakan untuk melihat nilai rata-rata dari setiap metrik pada masing-masing varian model. Analisis komparatif digunakan untuk membandingkan model baseline dengan model hasil pruning dan fine-tuning.

Efektivitas pengurangan ukuran model dihitung menggunakan rasio kompresi dengan persamaan berikut.

$$CR = \left(1 - \frac{P_{akhir}}{P_{awal}}\right) \times 100\%$$

Pada persamaan tersebut, CR adalah rasio kompresi, P_{akhir} adalah jumlah parameter model setelah pruning, dan P_{awal} adalah jumlah parameter model sebelum pruning. Hasil analisis digunakan untuk menentukan konfigurasi model yang paling optimal berdasarkan keseimbangan antara efisiensi komputasi dan kualitas rekomendasi.

BAB 4. HASIL YANG DICAPAI DAN POTENSI KHUSUS

4.1 Hasil yang Dicapai

Pengujian dilakukan terhadap tujuh varian model, yaitu satu model baseline, tiga model hasil Structured Pruning tanpa fine-tuning, dan tiga model hasil Structured Pruning dengan fine-tuning QLoRA. Setiap varian diuji menggunakan 50 kueri uji yang sama untuk memperoleh hasil evaluasi yang dapat dibandingkan secara adil. Evaluasi dilakukan pada dua aspek utama, yaitu efisiensi komputasi dan kualitas rekomendasi.

Tabel 4.1 Ringkasan Hasil Evaluasi Model

Model	TTFT (s)	Latency (s)	VRAM (GB)	Throughput (s)	NDCG @10	Recall @10	Hit Rate @10	Precision @10
Base_14 B	0.610	2.3096	27.6973	44.735	0.8409	0.9776	1.000	0.7837
Pruned10 P	0.031	0.5887	25.6394	55.477	0.8195	0.9724	1.000	0.7816
Pruned20 P	0.029	0.7041	23.5820	55.998	0.8180	0.9714	1.000	0.7837

Model	TTFT (s)	Latency(s)	VRAM(GB)	Throughput (s)	NDCG@10	Recall@10	Hit Rate@10	Precision@10
Pruned30P	0.028	0.6997	21.6730	56.087	0.8159	0.9643	1.000	0.7816
Pruned10FT	0.030	0.6355	25.6394	55.364	0.8170	0.9837	1.000	0.7918
Pruned20PFT	0.028	0.6861	23.5820	55.940	0.8321	0.9681	1.000	0.7837
Pruned30PFT	0.027	0.6023	21.6730	55.512	0.7918	0.9646	1.000	0.7796

4.1.1 Hasil Evaluasi Efisiensi Komputasi


Hasil evaluasi menunjukkan bahwa *Structured Pruning* mampu menurunkan kebutuhan komputasi model. Peak VRAM menurun dari 27,70 GB pada model baseline menjadi 25,64 GB pada pruning 10%, 23,58 GB pada pruning 20%, dan 21,67 GB pada pruning 30%. Selain itu, total latency juga turun dari 2,31 detik pada baseline menjadi sekitar 0,59–0,70 detik pada model hasil pruning. Nilai TTFT menurun dari 0,6100 detik menjadi di bawah 0,032 detik, sedangkan throughput meningkat dari 44,74 token/detik menjadi sekitar 55,4–56,1 token/detik. Hasil ini menunjukkan bahwa pruning berpengaruh langsung terhadap peningkatan efisiensi komputasi, terutama pada penggunaan VRAM, kecepatan respons, dan jumlah token yang dihasilkan per detik.

4.1.2 Hasil Evaluasi Kualitas Rekomendasi

Evaluasi kualitas rekomendasi dilakukan menggunakan metrik NDCG@10, Recall@10, Hit Rate@10, Precision@10, dan Parse Success Rate. Hasil evaluasi menunjukkan bahwa Base_14B memperoleh NDCG@10 tertinggi sebesar 0,8409. Namun, varian Pruned_20P_FT masih mampu mempertahankan kualitas yang mendekati baseline dengan NDCG@10 sebesar 0,8321 atau hanya turun sekitar 1,05%. Sebaliknya, Pruned_30P_FT mengalami penurunan kualitas yang lebih besar dengan NDCG@10 sebesar 0,7918 dan Parse Success Rate sebesar 0,40. Sementara itu, Hit Rate@10 bernilai 1,000 pada seluruh varian model, sehingga kemampuan dasar sistem dalam menemukan item relevan pada 10 rekomendasi teratas tetap terjaga.

4.3 Analisis *Trade-off* Model

Analisis trade-off dilakukan untuk menentukan konfigurasi model yang paling seimbang antara efisiensi komputasi dan kualitas rekomendasi. Pada penelitian ini, kualitas rekomendasi diwakili oleh NDCG@10, sedangkan efisiensi komputasi diwakili oleh latency dan Peak VRAM. Oleh karena itu, dua kurva utama yang digunakan adalah NDCG@10 terhadap latency dan NDCG@10 terhadap Peak VRAM, sebagaimana ditunjukkan pada Gambar 4.1.



Gambar 4.1 Kurva Trade-off Kualitas Rekomendasi terhadap Efisiensi Komputasi: (a) NDCG@10 terhadap Latency dan (b) NDCG@10 terhadap Peak VRAM

Berdasarkan kedua kurva tersebut, varian Pruned₂₀P_FT menunjukkan keseimbangan terbaik. Model ini mampu mempertahankan NDCG@10 sebesar 0,8321, hanya sedikit lebih rendah dari baseline sebesar 0,8409, tetapi memiliki efisiensi yang jauh lebih baik. Pruned₂₀P_FT menurunkan latency sekitar 70,29% dan mengurangi Peak VRAM dari 27,70 GB menjadi 23,58 GB atau sekitar

14,86%. Dengan demikian, Pruned_20P_FT dipilih sebagai konfigurasi terbaik karena mampu meningkatkan efisiensi komputasi tanpa menurunkan kualitas rekomendasi secara signifikan.

4.4 Potensi Khusus Hasil Penelitian

Hasil penelitian ini memiliki potensi khusus dalam pengembangan sistem rekomendasi berbasis LLM yang lebih efisien. Integrasi Structured Pruning dan QLoRA, khususnya pada konfigurasi Pruned_20P_FT, menunjukkan bahwa model dapat dibuat lebih ringan tanpa menurunkan kualitas rekomendasi secara signifikan. Temuan ini dapat menjadi acuan teknis untuk menerapkan LLM pada server dengan sumber daya komputasi terbatas.

Dari sisi penerapan, sistem rekomendasi ini berpotensi dikembangkan sebagai dasar asisten digital pariwisata Danau Toba yang mampu membantu pengguna memperoleh rekomendasi destinasi atau rencana perjalanan. Selain itu, hasil penelitian ini juga dapat menjadi dasar pengembangan lanjutan, seperti pengujian variasi pruning, konfigurasi QLoRA, quantization, serta penerapan pada domain pariwisata lain yang membutuhkan sistem rekomendasi berbasis bahasa alami.

BAB 5. PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan hal-hal berikut.

1. Structured Pruning terbukti mampu menurunkan kebutuhan komputasi model Qwen3-14B. Peak VRAM menurun dari 27,70 GB pada model baseline menjadi 21,67 GB pada konfigurasi pruning 30%, sedangkan latency turun dari 2,31 detik menjadi sekitar 0,59–0,70 detik pada seluruh varian model hasil pruning.
2. Penerapan QLoRA mampu membantu mempertahankan kualitas rekomendasi pada model hasil pruning ringan hingga menengah. Varian Pruned_20P_FT memperoleh NDCG@10 sebesar 0,8321, hanya sedikit lebih rendah dibandingkan baseline sebesar 0,8409, sehingga menunjukkan bahwa kualitas rekomendasi tetap terjaga.
3. Berdasarkan analisis trade-off antara efisiensi komputasi dan kualitas rekomendasi, Pruned_20P_FT menjadi konfigurasi terbaik. Model ini mampu menurunkan Peak VRAM sebesar 14,86%, mempercepat latency sebesar 70,29%, dan tetap mempertahankan kualitas rekomendasi yang mendekati baseline.
4. Pruning sebesar 30% menghasilkan efisiensi komputasi paling tinggi, tetapi menyebabkan penurunan kualitas rekomendasi yang lebih besar, terutama pada Pruned_30P_FT dengan NDCG@10 sebesar 0,7918 dan Parse Success Rate sebesar 0,40. Hal ini menunjukkan bahwa rasio pruning yang terlalu

tinggi dapat menurunkan kemampuan model dalam menghasilkan keluaran rekomendasi yang baik.

5.2 Saran

Berdasarkan hasil penelitian, beberapa saran untuk pengembangan selanjutnya adalah sebagai berikut.

1. Penelitian selanjutnya disarankan untuk menambah jumlah kueri uji agar evaluasi kualitas rekomendasi dapat dilakukan dengan hasil yang lebih kuat dan stabil.
2. Konfigurasi QLoRA dapat dikembangkan lebih lanjut, misalnya dengan menguji variasi rank yang berbeda pada setiap rasio pruning untuk mengetahui pengaruhnya terhadap pemulihan kualitas model.
3. Penelitian lanjutan juga dapat menguji metode optimasi tambahan, seperti quantization atau layer-sensitive pruning, agar model dapat berjalan lebih efisien pada perangkat dengan kapasitas GPU yang lebih terbatas.
4. Pendekatan ini dapat diterapkan pada domain pariwisata lain atau sistem rekomendasi berbasis bahasa Indonesia untuk menguji kemampuan generalisasi model di luar konteks Danau Toba

DAFTAR PUSTAKA

- Behera, A.P. *et al.* (2025) "Towards Efficient Multi-LLM Inference: Characterization and Analysis of LLM Routing and Hierarchical Techniques," 14(8), pp. 1–16.
- Bonin, B., Heuillet, M. and Durand, A. (2025) "LLM-as-a-Judge: Toward World Models for Slate Recommendation Systems," (i).
- Dettmers, T. *et al.* (2023) "QLoRA: Efficient Finetuning of Quantized LLMs," *Advances in Neural Information Processing Systems*, 36. Available at: <https://doi.org/https://doi.org/10.48550/arXiv.2305.14314>.
- Ma, X., Fang, G. and Wang, X. (2023) "LLM-Pruner: On the Structural Pruning of Large Language Models," *Advances in Neural Information Processing Systems*, 36. Available at: <https://doi.org/https://doi.org/10.48550/arXiv.2305.11627>.
- Tian, Y. *et al.* (2025) "Frustratingly Easy Task-aware Pruning for Large Language Models," pp. 1–8. Available at: <https://doi.org/https://doi.org/10.48550/arXiv.2510.22489>.
- Tsai, A.Y. *et al.* (2024) "Leveraging LLM Reasoning Enhances Personalized Recommender Systems."
- Yuan, Z. *et al.* (2025) "EfficientLLM: Efficiency in Large Language Models." Available at: <https://doi.org/https://doi.org/10.48550/arXiv.2505.13840>.


LAMPIRAN

Lampiran 1. Penggunaan Dana


Judul	OPTIMALISASI LARGE LANGUAGE MODEL DENGAN METODE STRUCTURED PRUNING DAN KUANTISASI UNTUK MENINGKATKAN EFISIENSI SISTEM REKOMENDASI PARIWISATA DANAU TOBA			
Skema	Tahun	Pendanaan	Penggunaan	Sisa
PKM-RE	2026	Rp 7.200.000	Rp.	Rp.

No	Tanggal	Keterangan	Harga Satuan	Jumlah	Total	Berkas	Validasi
1	06-04-2026		Rp.		Rp.		
2	07-04-2026		Rp.		Rp.		
3	08-04-2026		Rp.		Rp.		
4	09-04-2026		Rp.		Rp.		
5	10-04-2026		Rp.		Rp.		


Lampiran 2. Bukti-bukti pendukung kegiatan




Perbandingan Metrik Inferensi — 7 Varian Model (Two-Stage Generative)




Perbandingan Metrik Kualitas Respon – 7 Varian Model (Two-Stage Generative)






Qwen-14B Optimization Analysis: Structured Pruning + QLoRA (V3)


Pareto Front: Accuracy vs. Speed




Memory Footprint: Peak VRAM Consumption



Evaluation of Qwen-14B Optimization Strategies (Lake Toba Tourism Task)



Memory Efficiency: Peak VRAM Usage



AutoSave: Off | granular_eval_data.csv | Search

File Home Insert Draw Page Layout Formulas Data Review View Help | Foxit PDF | Table Design | Query

Table Name: granular_eval_data | Properties | Tools | External Table Data

Table Design: Header Row, First Column, Last Column, Banded Rows, Banded Columns, Table Style Options

Query: granular_eval_data (2) | 50 rows loaded

Query	NDCG	Latency	Throughput	VRAM
1	10	6,50416E+15	3,77283E+15	2,58666E+16
2	10	1,37565E+16	3,785E+14	2,63398E+15
3	10	6,06259E+14	3,80437E+15	2,58825E+15
4	10	3,35568E+16	3,77361E+15	2,57983E+16
5	10	2,49044E+15	3,77927E+16	2,57996E+15
6	10	1,37514E+16	3,78892E+16	2,63398E+15
7	10	3,60779E+15	3,80721E+16	2,57977E+16
8	0	5,86212E+15	3,79564E+15	2,58698E+16
9	10	1,48746E+16	3,7433E+15	2,57978E+16
10	0	5,74214E+15	3,78106E+15	2,58619E+15
11	10	6,3093E+15	9,87258E+15	3,77811E+16
12	0	3,4802E+15	3,77214E+16	2,57988E+15
13	10	8,49572E+15	3,75782E+16	2,57989E+16
14	10	1,38013E+16	3,77778E+15	2,63398E+15
15	10	1,05281E+16	3,79181E+15	2,57989E+16
16	10	1,37563E+16	3,77987E+15	2,63398E+15
17	0	2,4281E+16	3,76814E+15	2,57981E+16
18	0	2,50322E+16	3,78194E+16	2,57987E+16
19	0	1,37801E+16	3,77849E+15	2,63398E+15
20	0	2,51655E+16	3,77195E+15	2,57991E+16
21	0	6,40244E+15	3,79567E+15	2,5903E+16
22	0	7,33075E+15	3,78902E+15	2,59566E+16
23	0	7,18849E+15	3,47497E+15	2,57983E+16
24	0	8,18346E+15	3,81209E+15	2,60102E+16
25	10	1,42727E+15	3,75003E+15	2,57983E+16
26	10	7,47221E+15	3,75814E+15	2,59613E+16
27	0	6,42333E+15	3,80875E+15	2,5903E+16

Ready | Accessibility: Unavailable | 11:04 | 08/03/2026



How can I help you?

Sistem Rekomendasi & Asisten Cerdas Danau Toba

Wisata Alam
Hidden gem di Balige



Itinerary
Rencana perjalanan lengkap

Kuliner
Rekomendasi makanan halal


Edukasi
Sejarah & Geologi

Ask anything about Danau Toba...

AI generated content may be inaccurate.



Lampiran 3. Business Model Canvas (BMC)



Link to Miro:

https://miro.com/app/board/uXjVHTVRGhk=?share_link_id=30052723993